

[Technical Report]

AI 기반 소상공인 맞춤형 광고 이미지 자동 생성 파이프라인 구축 (Go Gachi MVP)

Document Status: Final (Release MVP)

Date: 2026-06-18

Project: Go Gachi (AI Automated Ad Image Generator)

Author (Roles): 이건호(PM), 손승만(FE), 신현수(BE-Pipeline/팀장), 김예주(BE-Router/DB/Infra), 이수민(PE)

1. Executive Summary (핵심 요약)

1.1. Background & Objective

소상공인 다수는 매체별(인스타그램, 배달의민족, 당근마켓 등)로 요구되는 이미지 규격과 시각적 문법을 반영하여 광고물을 제작할 리소스(시간/비용/기술)가 부족함. 본 프로젝트는 사용자가 원본 메뉴 사진을 업로드하면, 타겟 채널과 목적에 최적화된 광고 이미지 및 카피라이팅을 자동으로 결합해 렌더링하는 AI 파이프라인을 구축하는 것을 목표로 함.

1.2. Key Results

- AI Pipeline:** `gpt-image-2` (Edit Mode) 및 `gpt-5.4-mini` 연동을 통한 3개 채널 7종 규격 자동 생성.
- Performance:** Pre-signed URL 아키텍처 도입으로 API Payload **99.99% 감소** (2.12MB → 0.3KB).
- Stability:** 동기(Sync) 방식의 한계를 극복하기 위해 비동기(Async) Job Polling 아키텍처 도입, Max Latency 241초 환경에서의 UI/UX 안정성 확보. 백엔드 테스트 (pytest) 399개 100% 통과.
- Quality (Evaluation):** 10개 핵심 Test Set 기반 정량적 프롬프트 평가(Prompt Evaluation) 결과 **평균 9.05 / 10.0점** 달성.

2. System Architecture & Technical Specs (시스템 아키텍처 및 명세)

2.1. Tech Stack & Infrastructure

각 레이어의 책임을 격리하고 확장성을 고려하여 인프라를 완전 분리 구축함.

- **Frontend:** Streamlit Cloud (UI/UX, Async Job Polling)
- **Backend:** Render + FastAPI (API Gateway, Job Manager, Model Inference Routing)
- **Database:** Supabase / PostgreSQL (User Auth, Job Metadata, Billing 추적)
- **Storage:** Cloudflare R2 (원본/생성 이미지 적재 및 Pre-signed URL 서빙)

2.2. Database Schema (주요 테이블 구조)

테이블 명	역할 및 기능
profiles	Supabase Auth와 연결되는 서비스 사용자 프로필 정보
generations	이미지 생성 요청 1건의 상태, 원본/결과 URL, 광고 문구, 폴더 FK 매핑
folders	마이페이지 내 사용자 생성 기록 분류용 디렉터리
api_usage	OpenAI 호출 비용(Token 기반 계산), 모델명, 캐시(Cache Hit) 여부 기록

2.3. Key API Endpoints (핵심 API 명세)

도메인별로 라우터를 분리하여 총 13개의 엔드포인트를 구축함. (모든 핵심 API는 JWT 인증 적용)

- **Generate:** POST /api/generate/jobs (비동기 큐 생성), GET /api/generate/jobs/{id} (상태 폴링)
- **Copy:** POST /api/copy/generate (광고 문구 생성 및 보정)
- **Assets:** POST /api/assets (다운로드용 Signed URL 생성)
- **Auth/Users:** GET /api/auth/me/generations (페이지네이션 적용된 생성 이력 조회)

2.4. Data Flow (Async Processing Pipeline)

외부 AI API 호출로 인한 병목을 클라이언트와 격리하기 위해 단방향 비동기 흐름 적용.

1. Client → Multipart Form (이미지+옵션) 전송 → FastAPI (Validation & RGB/PNG 정규화)
2. FastAPI → 비동기 Job 생성 후 Client 에 request_id 즉시 반환 (202 Accepted)
3. FastAPI Worker → LLM 카피라이팅(gpt-5.4-mini) → Vision 모델 호출(gpt-image-2)
4. FastAPI Worker → 결과물 Cloudflare R2 업로드 → Supabase Job Status success 업데이트

5. `Client` → 5초 주기 Polling → 완료 시 Pre-signed URL 수신 및 ZIP 다운로드 연동

3. AI Model & Prompt Engineering (AI 파이프라인)

3.1. Prompt Architecture (프롬프트 계층 설계)

프롬프트의 재사용성과 채널별 톤앤매너 제어를 위해 [시스템 → 채널 힌트 → 채널 공통 규칙 → 상세 유형 → 문구] 순서로 우선순위가 적용되는 계층 구조(Modular Prompting)를 설계함.

- **Layer 1 (System):** 원본 객체 보존, 해상도 최적화 등 글로벌 제약 조건. 프롬프트 버전(`PROMPT_VERSION`) 관리를 통한 캐시 무효화 제어.
- **Layer 2 (Channel):** 인스타그램(SNS 감성), 배달의민족(상품 중심, 호라이즌 스튜디오 배경), 당근마켓(실제 생활형 프로모션 감성).
- **Layer 3 (Detail & Copy):** 1:1/4:5/9:16 비율 조정, 텍스트 배치(`preserve` / `polish` / `rewrite`) 파라미터 삽입.

3.2. Evaluation Framework (프롬프트 평가 체계)

결과물의 정성적 주관성을 배제하기 위해 10개 핵심 시나리오(S1~S10)를 정의하고, 채널별 시각 규칙(오브젝트 유무, 시야각 등) 통과 여부를 Pass/Fail 및 0~10점 척도로 수치화하는 정량 평가 체계 도입.

4. Architectural Decision Records (ADR, 주요 의사결정)

ADR 1: Generate vs. Edit 모드 선택 (Vision Model)

- **Decision:** `gpt-image-2` 의 Edit Mode 채택.
- **Rationale:** Generate 모드는 심미성은 높으나 상품의 고유 형태(Identity)를 변형시킴. 소상공인에게 가장 중요한 것은 '실제 판매하는 상품의 원본 보존'이므로, 프롬프트 튜닝 난이도를 감수하고 Edit 모드를 유지함.

ADR 2: 텍스트 후처리(Watermarking) vs. AI 통합 렌더링

- **Decision:** 백엔드에서의 프로그래매틱 강제 합성을 배제하고, AI 프롬프트에 텍스트를 삽입하여 동시 렌더링 유도.
- **Rationale:** 강제 합성은 철자 정확도를 보장하나 광고물의 디자인 톤앤매너를 심각하게 저해함. AI 통합 렌더링이 상업용 광고물 퀄리티 확보에 더 적합함.

ADR 3: API Payload 최적화 (Base64 → Pre-signed URL)

- **Decision:** JSON 응답 내 Base64 인코딩 방식을 폐기하고, R2 스토리지 업로드 후 Download URL 반환.
- **Rationale:** Base64 방식은 메모리 오버헤드 및 대역폭 병목을 초래함. Payload 경량화 및 브라우저 렌더링 성능 향상을 위해 R2 연동 방식을 채택함.

ADR 4: 텍스트 생성 전용 경량 모델 도입

- **Decision:** 카피라이팅 단계 모델을 `gpt-5` 대신 경량화 모델인 `gpt-5.4-mini` 로 변경.
- **Rationale:** 인퍼런스 비용과 대기 시간을 최적화하기 위해 도입했으며, MVP 수준의 반복적인 짧은 카피라이팅 태스크에서 충분한 품질 확보가 가능함.

5. Key Metrics & Performance (성능 지표 및 검증)

5.1. System Latency (생성 소요 시간 실측)

파이프라인 전 구간에 `X-Request-ID` 기반 타이밍 로그를 적용하여 199건의 In-production 요청 실측. 외부 API 병목이 최대 241초까지 발생함을 확인하였으며, 이는 **Async Job Polling** 아키텍처 채택이 필수적이었음을 증명함.

Pipeline Type	Requests	Avg Latency	Min Latency	Max Latency
Image Only	134	62.44s	17.43s	201.52s
Image + Copy (<code>gpt-5.4-mini</code>)	35	78.95s	28.45s	241.11s

5.2. Payload Reduction (페이로드 초경량화)

URL 서빙 방식으로 개편 후, API 네트워크 트래픽 부하 **99.99% 원천 제거**.

Metric	Legacy (Base64 Data URI)	Current (R2 Pre-signed URL)	Improvement
Average Payload Size	약 2.12 MB	약 0.30 KB	99.99% 감소

5.3. Pipeline Optimization (캐시 및 정규화 최적화)

- **Cache Hit 로직 적용:** 파이프라인 내 `cache_lookup` 구간을 신설, 중복 요청 시 OpenAI 호출을 Bypass하여 인퍼런스 비용/대기 시간 제거.
- **이미지 정규화:** `Invalid image file or mode` 오류 방지를 위해 EXIF 방향 보정 및 RGB/PNG 정규화 로직 적용.

6. Team Contributions (팀 구성 및 직무별 핵심 구현 내용)

- **이건호 (PM):** 채널별 테스트 시나리오(10개) 및 정량 평가 지표(Pass/Fail) 설계. A/B 테스트 결과를 수치화하여 PE에게 프롬프트 튜닝 가이드라인(수정 전후 비교표) 제공 및 프로젝트 전체 의사결정 주도.
- **손승만 (FE):** Streamlit의 Session State 한계를 극복한 다중 선택/일괄 다운로드 (ZIP) 구현. Polling 대기 간 이탈 방지를 위한 동적 로딩 애니메이션(소상공인 팁 17종 순환 노출) 및 반응형 모달 뷰 설계.
- **신현수 (BE-Pipeline / 팀장):** Edit 모드 기반 이미지 처리 파이프라인 베이스라인 통합 구축. 이미지 정규화(EXIF 보정) 로직 구현 및 `userPrompt` 와 `userCopy` 분리를 통한 프롬프트 엔지니어링 캡슐화 달성.
- **김예주 (BE-Router/DB/Infra):** FastAPI 라우팅 구조 확립. Supabase JWT 인증 기반 사용자 격리 아키텍처, R2 Signed URL을 통한 다운로드 보안 강화. DB 스키마 확장을 통한 OpenAI 토큰 사용량/비용 정밀 추적 시스템 구축.
- **이수민 (PE):** 매체별 목적(SNS 브랜딩 vs 정보 전달 vs 프로모션)에 따른 계층형 프롬프트 설계. 배달의민족 공간 배경을 '호라이즌 스튜디오 콘셉트'로 재정의하여 환각 현상을 통제하고 품질 최적화 수행.

7. Retrospective & Action Items (팀 회고 및 향후 과제)

7.1. Retrospective (팀 회고)

- 👍 **잘된 것 (What Went Well):**
초기 기획 스펙인 '3채널 × 7개 세부 유형 × 3가지 문구 모드'의 전 조합을 실서비스 수준으로 구현 완료. 비동기 Job 방식 도입을 통해 2분이 넘는 AI 추론 시간 속에서도 사용자가 이탈하지 않는 안정적인 흐름을 설계함.
- 😞 **아쉬운 것 (What Could Be Improved):**
Edit 모드의 한계로 인해 배경 변화의 자유도 제약 및 소형 오브젝트(슈가코인 등)의 33% 소실 문제 발생. 또한, 로고 정규화 시 발생하는 연산 병목(55초)을 해결하지 못해 브랜드 로고 합성 기능을 MVP 스코프에서 제외한 점이 아쉬움.
- 💡 **배운 것 (Lessons Learned):**
AI 모델 활용 시 발생하는 환각과 한계를 직접 체험하며 '프롬프트 설계(PE)와 파이프라인 제어(BE)의 분업화'의 중요성을 깨달음. 주관성에 의존하지 않고 시나리오 기반 정량 지표를 수립하여 품질을 통제하는 테스트 체계를 체득함.

7.2. Action Items (향후 고도화 방향)

- **도메인 환각(Hallucination) 제어:** 당근마켓 플랫폼 과해석 방지를 위해 시스템 프롬프트(Layer 1)에 강력한 Negative Prompting 배포 핫픽스 진행.
- **기술 부채 해소:** 브랜드 로고 합성 기능을 차기 고도화 스코프로 이관하여 재설계. 다운로드 Signed URL 만료 UX 개선 및 API Rate Limit(호출 제한) 적용 예정.